



UNIVERSIDADE FEDERAL DE SANTA CATARINA
CAMPUS JOINVILLE
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA DE SISTEMAS ELETRÔNICOS

Gabriel Brandão Santos

**Relatório Demonstrativo da Relação entre Teorema de Bayes e o Filtro de
Kalman**

Joinville/SC

2026

RELATÓRIO DEMONSTRATIVO DA RELAÇÃO ENTRE TEOREMA DE BAYES E O FILTRO DE KALMAN

Gabriel Brandão Santos

Trabalho Parcial submetido ao Programa de Pós-Graduação em Engenharia de Sistemas Eletrônicos, da Universidade Federal de Santa Catarina para avaliação parcial da disciplina Estatística para análise de dados - ESE410034.

Professora: Dra. Anelize Zomkowski Salvi

Joinville/SC

2026

Sumário

1	RELAÇÃO TEOREMA DE BAYES E O FILTRO DE KALMAN . .	2
1.1	Predição	2
1.2	Atualização	4
2	EQUAÇÕES MATRICIAIS DO FILTRO	5
2.1	Gerais	5
2.2	Particular da Fusão 1D	5

1 Relação Teorema de Bayes e o Filtro de Kalman

Temos o Teorema de Bayes abaixo:

$$p(\mu|z) = \frac{p(z|\mu) \cdot p(\mu)}{p(z)} \quad (1.1)$$

Nesta notação, μ consiste no estado e z seria a medição (para o exemplo do trabalho, a medição do acelerômetro).

Para o objetivo de determinar um estado ao longo do tempo, este teorema pode ser usado de forma recursiva, como na expressão abaixo:

$$p(\mu_k|z_{1:k}) = \frac{p(z_k|\mu_k) \cdot p(\mu_k|z_{1:k-1})}{p(z_k)} \quad (1.2)$$

Nesta forma, $p(\mu_k|z_{1:k-1})$ é a probabilidade a priori (Predição), que significa a probabilidade do estado ser μ no instante k dado todo o histórico de medições do acelerômetro de 1 até $k - 1$. $p(z_k|\mu_k)$ é a verossimilhança da medição, que consiste na probabilidade de medir z_k no acelerômetro dado que o estado verdadeiro do sistema é μ_k .

Por fim, $p(\mu_k|z_{1:k})$ é a probabilidade a posteriori (Atualização/Correção), que é a probabilidade do estado ser μ no instante k dado todo o histórico de medições de 1 até o exato momento k , ou seja, neste último passo, inclui-se a nova medição do acelerômetro.

A equação geral de modelagem dinâmica (que depois será particularizada para o caso do giroscópio na parte C) é:

$$\mu_k = A\mu_{k-1} + Bu_k + \epsilon_{k-1} \quad (1.3)$$

ϵ é o ruído da predição da modelagem dinâmica, que é assumido tendo distribuição normal $\epsilon \sim \mathcal{N}(0, Q)$. Q é a covariância deste ruído.

Consideramos também um modelo de observação linear, dado pela seguinte equação:

$$z_k = C\mu_k + \alpha_k \quad (1.4)$$

α_k é o ruído do acelerômetro, assumido também tendo uma distribuição normal ($\alpha_k \sim \mathcal{N}(0, R)$). R é a covariância deste ruído.

1.1 Predição

Se é assumido que a primeira estimativa era normal, ou seja, no instante $t = 0$, $\mu_0 \sim \mathcal{N}(\hat{\mu}_0, P_0)$, em que P_0 é a matriz de covariância inicial, então ao se propagar esta

estimativa na equação geral de modelagem dinâmica e no modelo de observação, estamos fazendo transformações lineares com gaussianas, que resultarão em uma nova gaussiana para o novo instante (propriedade de operações com gaussianas). Indutivamente o processo corre para os instantes futuros. Assim, a estimativa do instante anterior ($k - 1$) será sempre uma distribuição gaussiana, portanto:

$$p(\mu_{k-1}|z_{1:k-1}) = \mathcal{N}(\hat{\mu}_{k-1}, P_{k-1}) \quad (1.5)$$

Ou seja, a probabilidade do estado atual ser μ no instante $k - 1$, dado os valores das medições até este mesmo instante, é modelada como uma normal.

Desta forma, como μ_{k-1} e ϵ_{k-1} são normais, ao se calcular o valor esperado da equação de modelagem dinâmica, temos que:

$$\begin{aligned} E[\mu_k] &= E[A\mu_{k-1} + Bu_k + \epsilon_{k-1}] \\ E[\mu_k] &= A \cdot E[\mu_{k-1}] + B \cdot E[u_k] + E[\epsilon_{k-1}] \end{aligned} \quad (1.6)$$

Como $E[\mu_{k-1}] = \hat{\mu}_{k-1}$, $E[u_k] = u_k$ (valor medido pelo giroscópio, não aleatório) e $E[\epsilon_{k-1}] = 0$ (assumido acima para este erro), temos:

$$\hat{\mu}_k^- = A\hat{\mu}_{k-1} + Bu_k \quad (1.7)$$

O erro de predição é dado por:

$$\begin{aligned} e_k^- &= \mu_k - \hat{\mu}_k^- \\ &= (A\mu_{k-1} + Bu_k + \epsilon_{k-1}) - (A\hat{\mu}_{k-1} + Bu_k) \\ &= A(\mu_{k-1} - \hat{\mu}_{k-1}) + \epsilon_{k-1} \\ &= Ae_{k-1} + \epsilon_{k-1} \end{aligned} \quad (1.8)$$

A covariância é o valor esperado do erro de predição ao quadrado, assim:

$$\begin{aligned} P_k^- &= E[e_k^- (e_k^-)^T] \\ &= E[(Ae_{k-1} + \epsilon_{k-1})(Ae_{k-1} + \epsilon_{k-1})^T] \\ &= E[Ae_{k-1}e_{k-1}^T A^T + Ae_{k-1}\epsilon_{k-1}^T + \epsilon_{k-1}e_{k-1}^T A^T + \epsilon_{k-1}\epsilon_{k-1}^T] \end{aligned} \quad (1.9)$$

Como ϵ_{k-1} e e_{k-1} não possuem correlação, o segundo e terceiro termo são 0 e assim:

$$P_k^- = A \cdot E[e_{k-1}e_{k-1}^T] \cdot A^T + E[\epsilon_{k-1}\epsilon_{k-1}^T] \quad (1.10)$$

Temos que $E[e_{k-1}e_{k-1}^T] = P_{k-1}$ e $E[\epsilon_{k-1}\epsilon_{k-1}^T] = Q$, assim:

$$P_k^- = AP_{k-1}A^T + Q \quad (1.11)$$

1.2 Atualização

A probabilidade $p(z_k|\mu_k)$ que consiste na probabilidade de medir z_k no acelerômetro dado que o estado verdadeiro do sistema é μ_k é a verossimilhança.

Como foi assumido um modelo de observação dado por:

$$z_k = C\mu_k + \alpha_k \quad (1.12)$$

Onde α_k é o ruído do acelerômetro, assumido também ter uma distribuição normal ($\alpha_k \sim \mathcal{N}(0, R)$). R é a covariância deste ruído.

Desta forma, temos que a verossimilhança será também uma distribuição normal:

$$p(z_k|\mu_k) = \mathcal{N}(C\mu_k, R) \quad (1.13)$$

A probabilidade a posteriori pode então ser obtida pelo Teorema de Bayes fazendo a multiplicação da probabilidade a priori com a verossimilhança, desta forma:

$$p(\mu_k|z_{1:k}) = \eta \cdot \mathcal{N}(C\mu_k, R) \cdot \mathcal{N}(\hat{\mu}_k^-, P_k^-) \quad (1.14)$$

Em que $\eta = 1/p(z_k)$. Como $p(z_k)$ não depende do estado, seu inverso é tratado como esta constante. Novamente, como está sendo feito o produto de duas gaussianas, resultará em uma nova gaussiana para a probabilidade a posteriori, assim:

$$p(\mu_k|z_{1:k}) = \mathcal{N}(\hat{\mu}_k, P_k) \quad (1.15)$$

2 Equações Matriciais do Filtro

2.1 Gerais

Predição do estado:

$$\hat{\mu}_k^- = A\hat{\mu}_{k-1} + Bu_k \quad (2.1)$$

Covariância do erro:

$$P_k^- = AP_{k-1}A^T + Q \quad (2.2)$$

Ganho de Kalman:

$$K_k = P_k^- C^T (CP_k^- C^T + R)^{-1} \quad (2.3)$$

Atualização do estado:

$$\hat{\mu}_k = \hat{\mu}_k^- + K_k(z_k - C\hat{\mu}_k^-) \quad (2.4)$$

Atualização da matriz de covariância do erro:

$$P_k = P_k^- - K_k C P_k^- \quad (2.5)$$

2.2 Particular da Fusão 1D

$$\mu_k = \begin{bmatrix} \theta_k \\ b_k \end{bmatrix} \quad (2.6)$$

$$\theta_k = \theta_{k-1} + (u_k - b_{k-1}) \cdot \Delta t \quad (2.7)$$

$$b_k = b_{k-1} \quad (2.8)$$

$$A = \begin{bmatrix} 1 & -\Delta t \\ 0 & 1 \end{bmatrix} \quad (2.9)$$

$$B = \begin{bmatrix} \Delta t \\ 0 \end{bmatrix} \quad (2.10)$$

$$C = \begin{bmatrix} 1 & 0 \end{bmatrix} \quad (2.11)$$

$$Q = \begin{bmatrix} Q_\theta & 0 \\ 0 & Q_b \end{bmatrix} \quad (2.12)$$