



UNIVERSIDADE FEDERAL DE SANTA CATARINA
CAMPUS JOINVILLE
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA DE SISTEMAS ELETRÔNICOS

Gabriel Brandão Santos

**Relatório Demonstrativo da Relação entre Teorema de Bayes e o Filtro de
Kalman**

Joinville/SC

2026

RELATÓRIO DEMONSTRATIVO DA RELAÇÃO ENTRE TEOREMA DE BAYES E O FILTRO DE KALMAN

Gabriel Brandão Santos

Trabalho parcial submetido ao Programa de Pós-Graduação em Engenharia de Sistemas Eletrônicos da Universidade Federal de Santa Catarina para avaliação parcial da disciplina Estatística para análise de dados - ESE410034.

Professora: Dra. Anelize Zomkowski Salvi

Joinville/SC

2026

Sumário

1	RELAÇÃO TEOREMA DE BAYES E O FILTRO DE KALMAN . .	2
1.1	Predição	3
1.2	Atualização	4
2	EQUAÇÕES MATRICIAIS DO FILTRO	5
2.1	Gerais (obtidas anteriormente em parte)	5
2.2	Particular da Fusão 1D	5
3	ANÁLISE DOS RESULTADOS	7
3.1	Simulação com dados sintéticos	7
3.2	IMU SIMULADA	8
3.2.1	Descrição básica	8
3.2.2	Sintonização das matrizes	8
3.2.3	Resultados	8

1 Relação Teorema de Bayes e o Filtro de Kalman

O filtro de Kalman se baseia na aplicação do Teorema de Bayes e na adoção de distribuições gaussianas para a incerteza do modelo dinâmico e dos sensores. Ao ser assumido também comportamento linear dos sistemas, chega-se a um algoritmo recursivo que consegue estimar o estado do sistema com atualizações provenientes da medição dos sensores.

Temos o Teorema de Bayes abaixo:

$$p(\mu|z) = \frac{p(z|\mu) \cdot p(\mu)}{p(z)} \quad (1.1)$$

Nesta notação, μ consiste no estado e z seria a medição (para o exemplo do trabalho, a medição do acelerômetro).

Para o objetivo de determinar um estado ao longo do tempo, este teorema pode ser usado de forma recursiva, como na expressão a seguir.

$$p(\mu_k|z_{1:k}) = \frac{p(z_k|\mu_k) \cdot p(\mu_k|z_{1:k-1})}{p(z_k)} \quad (1.2)$$

Nesta forma, $p(\mu_k|z_{1:k-1})$ é a probabilidade a priori (Predição), que significa a probabilidade do estado ser μ no instante k dado todo o histórico de medições do acelerômetro de 1 até $k - 1$. $p(z_k|\mu_k)$ é a verossimilhança da medição, que consiste na probabilidade de medir z_k no acelerômetro dado que o estado verdadeiro do sistema é μ_k .

Por fim, $p(\mu_k|z_{1:k})$ é a probabilidade a posteriori (Atualização/Correção), que é a probabilidade do estado ser μ no instante k dado todo o histórico de medições de 1 até o exato momento k . Ou seja, inclui-se a nova medição do acelerômetro.

A equação geral de modelagem dinâmica (que depois será particularizada para o caso do giroscópio na parte C) é:

$$\mu_k = A\mu_{k-1} + Bu_k + \epsilon_{k-1} \quad (1.3)$$

ϵ é a incerteza da predição do modelo dinâmico, que é assumido tendo distribuição normal $\epsilon \sim \mathcal{N}(0, Q)$. Q é a covariância deste ruído.

Consideramos também um modelo de observação linear, dado pela seguinte equação:

$$z_k = C\mu_k + \alpha_k \quad (1.4)$$

α_k é o ruído do sensor (acelerômetro), assumido também tendo uma distribuição normal ($\alpha_k \sim \mathcal{N}(0, R)$). R é a covariância deste ruído.

1.1 Predição

Se a primeira estimativa é assumida sendo normal, ou seja, no instante $t = 0$, $\mu_0 \sim \mathcal{N}(\hat{\mu}_0, P_0)$, em que P_0 é a matriz de covariância inicial, então ao se propagar esta estimativa na equação geral de modelagem dinâmica e no modelo de observação, estaremos fazendo transformações lineares com gaussianas, que resultarão em uma nova gaussiana para o instante seguinte, neste caso $t = 1$ (propriedade de operações com gaussianas). Indutivamente o processo corre para os instantes futuros. Assim, a estimativa do instante anterior ($k - 1$) será sempre uma distribuição gaussiana, portanto:

$$p(\mu_{k-1}|z_{1:k-1}) = \mathcal{N}(\hat{\mu}_{k-1}, P_{k-1}) \quad (1.5)$$

Ou seja, a probabilidade do estado ser μ_{k-1} no instante $k - 1$, dado os valores das medições até este mesmo instante, é uma distribuição normal.

Desta forma, como μ_{k-1} e ϵ_{k-1} são normais, ao se calcular o valor esperado da equação de modelagem dinâmica, temos que:

$$\begin{aligned} E[\mu_k] &= E[A\mu_{k-1} + Bu_k + \epsilon_{k-1}] \\ E[\mu_k] &= A \cdot E[\mu_{k-1}] + B \cdot E[u_k] + E[\epsilon_{k-1}] \end{aligned} \quad (1.6)$$

Como $E[\mu_{k-1}] = \hat{\mu}_{k-1}$, $E[u_k] = u_k$ (valor medido pelo giroscópio, não aleatório) e $E[\epsilon_{k-1}] = 0$ (assumido acima para a distribuição deste erro), temos:

$$\hat{\mu}_k^- = A\hat{\mu}_{k-1} + Bu_k \quad (1.7)$$

O erro de predição é dado por:

$$\begin{aligned} e_k^- &= \mu_k - \hat{\mu}_k^- \\ &= (A\mu_{k-1} + Bu_k + \epsilon_{k-1}) - (A\hat{\mu}_{k-1} + Bu_k) \\ &= A(\mu_{k-1} - \hat{\mu}_{k-1}) + \epsilon_{k-1} \\ &= Ae_{k-1} + \epsilon_{k-1} \end{aligned} \quad (1.8)$$

A covariância é o valor esperado do erro de predição ao quadrado, assim:

$$\begin{aligned} P_k^- &= E[e_k^- (e_k^-)^T] \\ &= E[(Ae_{k-1} + \epsilon_{k-1})(Ae_{k-1} + \epsilon_{k-1})^T] \\ &= E[Ae_{k-1}e_{k-1}^T A^T + Ae_{k-1}\epsilon_{k-1}^T + \epsilon_{k-1}e_{k-1}^T A^T + \epsilon_{k-1}\epsilon_{k-1}^T] \end{aligned} \quad (1.9)$$

Como ϵ_{k-1} e e_{k-1} não possuem correlação, o segundo e terceiro termo são 0 e assim:

$$P_k^- = A \cdot E[e_{k-1}e_{k-1}^T] \cdot A^T + E[\epsilon_{k-1}\epsilon_{k-1}^T] \quad (1.10)$$

Temos que $E[e_{k-1}e_{k-1}^T] = P_{k-1}$ e $E[\epsilon_{k-1}\epsilon_{k-1}^T] = Q$, assim:

$$P_k^- = AP_{k-1}A^T + Q \quad (1.11)$$

1.2 Atualização

A probabilidade $p(z_k|\mu_k)$, que consiste na probabilidade de medir z_k no acelerômetro dado que o estado verdadeiro do sistema é μ_k , é a verossimilhança.

Como foi assumido um modelo de observação dado por:

$$z_k = C\mu_k + \alpha_k \quad (1.12)$$

Onde α_k é o ruído do acelerômetro, assumido também tendo uma distribuição normal ($\alpha_k \sim \mathcal{N}(0, R)$). R é a covariância deste ruído.

Desta forma, temos que a verossimilhança será também uma distribuição normal:

$$p(z_k|\mu_k) = \mathcal{N}(C\mu_k, R) \quad (1.13)$$

A probabilidade a posteriori pode então ser obtida pelo Teorema de Bayes fazendo a multiplicação da probabilidade a priori com a verossimilhança, desta forma:

$$p(\mu_k|z_{1:k}) = \eta \cdot \mathcal{N}(C\mu_k, R) \cdot \mathcal{N}(\hat{\mu}_k^-, P_k^-) \quad (1.14)$$

Em que $\eta = 1/p(z_k)$. Como $p(z_k)$ não depende do estado, seu inverso é tratado como esta constante. Novamente, como está sendo feito o produto de duas gaussianas, resultará em uma nova gaussiana para a probabilidade a posteriori, assim:

$$p(\mu_k|z_{1:k}) = \mathcal{N}(\hat{\mu}_k, P_k) \quad (1.15)$$

2 Equações Matriciais do Filtro

2.1 Gerais (obtidas anteriormente em parte)

Predição do estado:

$$\hat{\mu}_k^- = A\hat{\mu}_{k-1} + Bu_k \quad (2.1)$$

Covariância do erro:

$$P_k^- = AP_{k-1}A^T + Q \quad (2.2)$$

Ganho de Kalman:

$$K_k = P_k^- C^T (CP_k^- C^T + R)^{-1} \quad (2.3)$$

Atualização do estado:

$$\hat{\mu}_k = \hat{\mu}_k^- + K_k(z_k - C\hat{\mu}_k^-) \quad (2.4)$$

Atualização da matriz de covariância do erro:

$$P_k = P_k^- - K_k C P_k^- \quad (2.5)$$

2.2 Particular da Fusão 1D

Para o caso da fusão do giroscópio com o acelerômetro em uma estimativa 1D (ângulo de Roll), tem-se que o modelo dinâmico é regido pela física do giroscópio (variação do ângulo no tempo = velocidade angular) e é dado por:

$$\theta_k = \theta_{k-1} + (u_k - b_{k-1}) \cdot \Delta t \quad (2.6)$$

Em que u_k é a velocidade angular medida pelo giroscópio e o termo b_{k-1} é o bias do giroscópio, que consiste em um erro sistemático de leitura do sensor. É assumido que ele não varia tão rapidamente e é constante de um ciclo do filtro para outro, assim:

$$b_k = b_{k-1} \quad (2.7)$$

Expandindo a expressão do ângulo, temos:

$$\theta_k = \theta_{k-1} - \Delta t \cdot b_{k-1} + \Delta t \cdot u_k \quad (2.8)$$

E agrupando a equação do ângulo com a do bias em um único vetor, denominado vetor de estado μ , obtém-se a forma matricial abaixo.

$$\begin{bmatrix} \theta_k \\ b_k \end{bmatrix} = \begin{bmatrix} 1 & -\Delta t \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \theta_{k-1} \\ b_{k-1} \end{bmatrix} + \begin{bmatrix} \Delta t \\ 0 \end{bmatrix} u_k \quad (2.9)$$

Em que,

$$\mu_k = \begin{bmatrix} \theta_k \\ b_k \end{bmatrix} \quad (2.10)$$

$$A = \begin{bmatrix} 1 & -\Delta t \\ 0 & 1 \end{bmatrix} \quad (2.11)$$

$$B = \begin{bmatrix} \Delta t \\ 0 \end{bmatrix} \quad (2.12)$$

$$C = \begin{bmatrix} 1 & 0 \end{bmatrix} \quad (2.13)$$

3 Análise dos Resultados

3.1 Simulação com dados sintéticos

A Figura 1 mostra o uso do filtro de Kalman nos dados sintéticos. É observado o sinal real, uma senoide pura, os dados medidos pelo acelerômetro com ruído de alta variância e o sinal filtrado. Como o ruído do giroscópio era de baixa variância, o ganho de Kalman ponderou para o "lado" do modelo dinâmico, que usa a medição do giroscópio, assim a curva filtrada consegue modelar melhor o sinal real.




Figura 1 – Resultados dos dados sintéticos.

Foram observados os seguintes erros quadráticos médios (EQM):

- **EQM Acelerômetro (sem o filtro):** 0.4942
- **EQM Filtro de Kalman:** 0.0058
- **Ganho Estatístico:** 98.84%

Estes resultados mostram um erro alto para o acelerômetro por conta da alta variância embutida para ele na simulação. Ou seja, mesmo o acelerômetro não sofrendo de deriva, por possuir uma alta variância, não seria um bom estimador de estado deste sinal. O ganho estatístico mostra que o filtro de Kalman conseguiu eliminar o impacto do ruído do acelerômetro, aproveitando a informação do giroscópio de baixa variância.

3.2 IMU SIMULADA

3.2.1 Descrição básica

Utilizou-se o Webots para simular a IMU. No Webots, foi adicionado um *Robot* e em seguida um *HingeJoint*, que é um nó usado para representar uma junta de rotação em torno de um único eixo. Posteriormente, adicionou-se um *RotationalMotor* para fazer a movimentação. Um sólido (*box*) foi inserido para a rotação ser visualizada e nele foram acoplados os sensores.

O acelerômetro e o giroscópio foram inseridos com ruídos gaussianos para simular a incerteza dos sensores através da propriedade *lookupTable* (com mais variância para o acelerômetro). Para o acelerômetro, também foi inserido na propriedade *resolution* o valor de 0,01, isso simula que o sensor só consegue ler em "degraus" de valor, como um sensor digital real (ADC). O mesmo foi feito para o giroscópio, mas com *resolution* de 0,001 (geralmente sofre com menos ruído, mas tem deriva). O *bias* do giroscópio foi assumido como constante (0.003). O filtro de Kalman foi implementado pela classe desenvolvida na Parte A do trabalho. A IMU foi posta para girar no eixo do *roll* e os dados foram acompanhados por *plots* gerados em Python. O código da parte C no repositório foi associado ao *Robot* como o controlador (em *controller*).

3.2.2 Sintonização das matrizes

As matrizes Q e R foram sintonizadas por meio da coleta de 500 amostras mantendo o motor que movimenta a *box* parado (IMU Estática) para o cálculo da variância do acelerômetro e do giroscópio. A matriz R foi considerada a variância do acelerômetro e a matriz Q , a variância do giroscópio (a multiplicação do intervalo de tempo ao quadrado foi ignorada por dt ser um valor muito pequeno).

3.2.3 Resultados

A Figura 2 mostra que o sinal medido pelo acelerômetro na linha vermelha é bastante ruidoso e tem saltos irreais. O filtro de Kalman na linha azul consegue obter o comportamento real do movimento de forma suave e ignora oscilações bruscas. No entanto, é possível notar que existe um desvio em relação à trajetória e um atraso de fase. O filtro de Kalman está confiando muito mais na predição do giroscópio do que do acelerômetro, diminuindo o peso das correções do acelerômetro, o que gera o acúmulo de erro (deriva). Uma forma alternativa de sintonizar as matrizes poderia ser feita diminuindo o valor da matriz R e aumentando a matriz Q , forçando assim o filtro a confiar mais nas medições do acelerômetro e então reagir mais rápido às mudanças de direção.




Figura 2 – Resultados da IMU simulada.